

Predicción de supervivencia en el Titanic

Dr. Enrique Escalante

Junio 2026

1. Propósito

Construir y evaluar un sistema de clasificación supervisada para predecir la supervivencia de pasajeros del Titanic, representada mediante la variable *Survived*, cuyos valores son: 0: No sobrevivió; 1: Sobrevivió. El proyecto deberá implementar un flujo de trabajo reproducible mediante herramientas de *scikit-learn*, incluyendo el preprocesamiento, entrenamiento y evaluación de modelos dentro de una estructura clara, ordenada y metodológicamente defendible.

El énfasis principal no será obtener únicamente el mayor valor de una métrica, sino construir un procedimiento correcto, reproducible y justificable para resolver un problema de clasificación binaria.

2. Datos y variables

Se trabajará con el conjunto de datos Titanic, el cual contiene 12 variables correspondientes a información de los pasajeros. Las variables disponibles son: *PassengerId*, *Survived*, *Pclass*, *Name*, *Sex*, *Age*, *SibSp*, *Parch*, *Ticket*, *Fare*, *Cabin* y *Embarked*. La variable objetivo será: *Survived*, esta variable representa si un pasajero sobrevivió o no al naufragio.

3. Preprocesamiento obligatorio

El preprocesamiento deberá implementarse de forma reproducible mediante *ColumnTransformer* y *Pipeline* de *scikit-learn*. No se aceptará un preprocesamiento manual separado del modelo si este rompe la reproducibilidad del flujo de trabajo.

3.1. Limpieza y selección de variables

El estudiante deberá realizar una revisión inicial del conjunto de datos, considerando al menos los siguientes elementos:

- Dimensiones del conjunto de datos.

- Tipos de variables.

- Valores faltantes.

- Distribución de la variable *Survived*.

- Selección de variables predictoras.

- Separación entre variables predictoras y variable objetivo.

Como mínimo, deberá eliminarse la variable *PassengerId* del conjunto de predictores.

3.2. Tratamiento de valores faltantes

El tratamiento de valores faltantes deberá integrarse dentro del pipeline de preprocesamiento. Para las variables numéricas, los valores faltantes deberán imputarse usando la media de cada variable. Para las variables categóricas, los valores faltantes deberán imputarse usando la categoría *Unknown*. Las variables categóricas deberán transformarse mediante codificación *one-hot encoding*. Las variables categóricas obligatorias para este proceso son: *Sex* y *Embarked*. La codificación deberá manejar adecuadamente categorías no observadas durante el entrenamiento para evitar errores al evaluar el modelo con datos nuevos.

3.3. Escalamiento

Las variables numéricas deberán escalarse para garantizar un tratamiento adecuado en modelos sensibles a la escala, particularmente: Regresión logística y K vecinos más cercanos.

Aunque los modelos basados en árboles no requieren escalamiento de forma estricta, se mantendrá el

mismo flujo de preprocesamiento por orden, trazabilidad y comparabilidad entre modelos.

4. Partición de los datos

El conjunto de datos deberá dividirse en entrenamiento y prueba, usando una proporción de 80 % para entrenamiento y 20 % para prueba.

La partición deberá cumplir con las siguientes condiciones: usar una semilla aleatoria fija para garantizar reproducibilidad y mantener la proporción de clases de la variable Survived en los subconjuntos de entrenamiento y prueba.

La estratificación es obligatoria, ya que el problema puede presentar cierto desbalance entre las clases.

5. Modelos a evaluar

Se deberán entrenar y comparar cinco modelos de clasificación supervisada.

Regresión logística, la regresión logística será considerada como modelo base. Es un modelo interpretable, adecuado para establecer una primera referencia de desempeño y útil para problemas de clasificación binaria. K vecinos más cercanos, el modelo de K vecinos más cercanos funcionará como una referencia no paramétrica basada en distancias. Debido a su dependencia de la escala de las variables, requiere que las variables numéricas sean escaladas adecuadamente.

Árbol de decisión, el árbol de decisión permitirá construir un modelo interpretable basado en reglas de separación. Sin embargo, deberá cuidarse el posible sobreajuste mediante restricciones razonables en su profundidad y complejidad.

Bosque aleatorio, el bosque aleatorio será utilizado como modelo de ensamble basado en múltiples árboles de decisión. Se espera que tenga mayor estabilidad y capacidad predictiva que un árbol individual. Modelo de boosting, el quinto modelo deberá corresponder a una técnica de boosting. Se podrá utilizar un modelo moderno de boosting basado en histogramas o un modelo clásico de *gradient boosting*.

El modelo elegido deberá justificarse brevemente en el reporte, indicando por qué resulta adecuado para datos tabulares y para un problema de clasificación binaria.

6. Métricas de evaluación

Cada modelo deberá evaluarse sobre el conjunto de prueba mediante las siguientes

métricas: Exactitud.

Precisión.

Sensibilidad o exhaustividad.

Puntaje F1.

Área bajo la curva ROC.

Además, deberá presentarse la matriz de confusión del mejor modelo.

La exactitud no deberá interpretarse de manera aislada. Debido a que el problema puede presentar desbalance entre clases, el análisis deberá considerar especialmente la precisión, la sensibilidad, el puntaje F1 y el área bajo la curva ROC.

7. Validación adicional recomendada

Además de la partición simple en entrenamiento y prueba, se recomienda realizar validación cruzada estratificada con cinco particiones. Esta validación permitirá analizar la estabilidad del desempeño de los modelos y reducir la dependencia de una única partición de los datos, reportar:

Desempeño promedio.

Variabilidad del desempeño.

Comentario sobre la estabilidad relativa de los modelos.

8. Entregables

El proyecto deberá entregar dos productos principales.

Notebook o script reproducible, deberá incluir, como mínimo:

1. Carga del conjunto de datos.
2. Exploración inicial del conjunto de datos.
3. Identificación de tipos de variables.
4. Identificación de valores faltantes.
5. Análisis de la distribución de Survived.
6. Selección de variables predictoras.
7. Separación entre predictores y variable objetivo.
8. Partición en entrenamiento y prueba.
9. Definición del preprocesamiento mediante pipeline.
10. Entrenamiento de los cinco modelos.
11. Evaluación de los cinco modelos.
12. Tabla comparativa de resultados.
13. Selección del mejor modelo.
14. Matriz de confusión del mejor modelo.
15. Comparación entre desempeño en entrenamiento y prueba.
16. Conclusión del análisis.

El archivo deberá ser ejecutable de principio a fin sin intervención manual adicional, salvo la disponibilidad del conjunto de datos.

Reporte breve en PDF, deberá tener una extensión sugerida de 2 a 4 páginas e incluir los siguientes apartados:

1. Introducción: Descripción breve del problema de clasificación, del conjunto de datos y de la variable objetivo.
2. Variables usadas: Descripción de las variables predictoras empleadas, indicando cuáles fueron numéricas y cuáles categóricas. También se deberá justificar la exclusión de variables como PassengerId, Name, Ticket y, en su caso, Cabin.
3. Diseño del preprocesamiento: Explicación del tratamiento aplicado a los datos, incluyendo:
 - Imputación de valores faltantes.
 - Codificación de variables categóricas.
 - Escalamiento de variables numéricas.
 - Uso de un pipeline reproducible.
4. Modelos evaluados: Descripción breve de los cinco modelos entrenados y evaluados.
5. Resultados: Presentación de una tabla comparativa con las métricas obligatorias:
 - Exactitud.
 - Precisión.
 - Sensibilidad.
 - Puntaje F1.
 - Área bajo la curva ROC.
6. Matriz de confusión: Presentación e interpretación de la matriz de confusión correspondiente al mejor modelo.
7. Análisis de sobreajuste: Comparación entre los resultados obtenidos en entrenamiento y prueba. El estudiante deberá comentar si el modelo seleccionado presenta indicios de:
 - Subajuste.
 - Ajuste razonable.
 - Sobreajuste.
8. Conclusión: La conclusión deberá indicar:
 - Qué modelo se selecciona como mejor.

- Por qué se selecciona dicho modelo.
- Cuáles son sus principales limitaciones.
- Qué mejoras podrían incorporarse en una segunda versión del proyecto.

9. Criterios de evaluación

Criterio	Puntaje
Carga correcta del conjunto de datos y exploración mínima	10
Selección adecuada de variables predictoras	10
Uso correcto de ColumnTransformer y Pipeline	20
Tratamiento correcto de valores faltantes, codificación y escalado	15
Entrenamiento de los cinco modelos solicitados	15
Evaluación con las métricas obligatorias	15
Tabla comparativa y matriz de confusión	5
Análisis de sobreajuste y conclusión	5
Claridad, orden y reproducibilidad del trabajo	5
Total	100