

Predicción de supervivencia en el Titanic

Comparación reproducible de cinco modelos mediante pipelines de scikit-learn, con preprocesamiento integrado, validación estratificada y evaluación final sobre un conjunto de prueba reservado.

Resultado técnico. Se seleccionó **HistGradientBoosting** por su F1 promedio de validación cruzada de **0.759**. En prueba alcanzó F1 **0.738** y ROC-AUC **0.814**. La brecha train/test de F1 fue +0.160, por lo que existen indicios de sobreajuste.

1. Introducción

El objetivo es predecir la variable binaria Survived, donde 0 significa "no sobrevivió" y 1 "sobrevivió". El conjunto contiene 891 pasajeros y 12 variables. La evaluación prioriza F1, sensibilidad y ROC-AUC además de exactitud, porque la clase positiva representa 38.38 % de las observaciones.

2. Variables usadas

Predictoras

Numéricas: Pclass, Age, SibSp, Parch y Fare.

Catóricas: Sex y Embarked.

Exclusiones

PassengerId es un identificador. **Name** y **Ticket** tienen alta cardinalidad. **Cabin** presenta 687 faltantes (77.10 %) y requeriría una estrategia específica fuera del alcance base.




Figura 1. Distribución de la variable objetivo: 549 no sobrevivientes y 342 sobrevivientes.

3. Diseño del preprocesamiento

La partición fue 80 % entrenamiento (712 filas) y 20 % prueba (179 filas), con `random_state=42` y estratificación. El `ColumnTransformer` aplica imputación por media y escalamiento a las variables numéricas. Para Sex y Embarked usa imputación con Unknown y one-hot encoding con categorías desconocidas ignoradas.

El transformador está dentro de cada Pipeline. Así, imputadores, escalador y codificador se ajustan exclusivamente con el subconjunto de entrenamiento de cada fold, lo que evita fuga de datos.

4. Modelos evaluados

Se compararon regresión logística como línea base interpretable; K vecinos como método basado en distancias; árbol de decisión restringido; bosque aleatorio como ensamble estable; e HistGradientBoosting como boosting eficiente para datos tabulares y relaciones no lineales.

5. Resultados

0.810
Exactitud

0.787
Precisión

0.696
Sensibilidad

0.738
F1

0.814
ROC-AUC

Modelo	Exact.	Prec.	Sens.	F1	ROC-AUC	F1 CV
HistGradientBoosting	0.810	0.787	0.696	0.738	0.814	0.759 ± 0.033
Bosque aleatorio	0.810	0.830	0.638	0.721	0.846	0.737 ± 0.024
Regresión logística	0.804	0.793	0.667	0.724	0.845	0.726 ± 0.034
Árbol de decisión	0.760	0.732	0.594	0.656	0.792	0.721 ± 0.013
K vecinos	0.810	0.787	0.696	0.738	0.859	0.720 ± 0.026

La selección no usa la prueba: ordena por F1 promedio de validación cruzada, después ROC-AUC promedio y finalmente menor variabilidad. La tabla resalta el modelo seleccionado.




Figura 2. Comparación de exactitud, F1 y ROC-AUC en prueba. Las cifras exactas se conservan en resultados/comparacion_modelos.csv.

6. Matriz de confusión

El modelo identificó 48 sobrevivientes y 97 no sobrevivientes correctamente. Produjo 13 falsos positivos y 21 falsos negativos. La sensibilidad de 0.696 muestra que aún se pierde una fracción relevante de la clase positiva.

Matriz de confusión: HistGradientBoosting
Conjunto de prueba, n=179




Figura 3. Matriz de confusión de HistGradientBoosting sobre 179 observaciones de prueba.

7. Análisis de sobreajuste

Indicios de sobreajuste

El F1 de entrenamiento fue 0.898 y el de prueba 0.738; la diferencia de +0.160 es material. Aunque la validación cruzada fue relativamente estable (desviación F1 0.033), el desempeño final indica que el boosting aprendió patrones más específicos del entrenamiento.

F1 en entrenamiento y prueba
Brechas grandes sugieren sobreajuste; la prueba no intervino en la selección




Figura 4. Comparación de F1 por modelo. La prueba se mantuvo fuera de la selección.

8. Conclusión

Modelo seleccionado: HistGradientBoosting. Se eligió por obtener el mayor F1 promedio de validación cruzada (0.759), con ROC-AUC promedio 0.877. El resultado confirma que un modelo no lineal puede capturar interacciones útiles en estas variables tabulares.

La selección es metodológicamente defendible, pero no implica que sea el mejor modelo para producción. En prueba, K vecinos igualó el F1 de 0.738 y otros modelos obtuvieron un ROC-AUC mayor. Además, la brecha train/test del seleccionado obliga a reportar sobreajuste.

Limitaciones principales

- El conjunto es pequeño, histórico y representa una situación específica.
- Se excluyen variables de texto y cabina para respetar el alcance; podrían contener señal útil.
- La partición de prueba tiene 179 casos, por lo que las métricas tienen incertidumbre.
- Las asociaciones predictivas no establecen causas de supervivencia.

Mejoras recomendadas

1. Agregar FamilySize, IsAlone y títulos extraídos de Name.
2. Regularizar el boosting y ajustar hiperparámetros con validación anidada.
3. Calibrar probabilidades y reportar intervalos de confianza.
4. Evaluar métricas por sexo y clase para detectar desempeño desigual.
5. Conservar un conjunto final bloqueado al iterar una segunda versión.

Reproducibilidad

El notebook ejecuta las 16 etapas solicitadas, guarda métricas y gráficos, prueba una categoría no observada y usa semilla fija. Las dependencias están definidas en `requirements.txt`; la guía de ejecución se encuentra en `README.md`.

Dictamen. El flujo cumple la consigna y es reproducible. El resultado debe comunicarse como una comparación académica con indicios de sobreajuste, no como un sistema listo para decisiones reales.